Master Dissertation

`Temporal-ML`: A meta-learning approach in movement prediction of aperiodic time-series data

NGUYEN BAO LONG

Supervisor: **Ryo Maezono**

Graduate School of Advanced Science and Technology
Japan Advanced Institute of Science and Technology

Abstract

Keywords: Aperiodic time-series data, Foreign exchange, Meta-learning, `BiLSTM`, `BiLSTM+CNN`, `Transformer`

Acknowledgements

I would like to express my gratitude to my thesis advisors, Prof. Ryo Maezono and Associate Prof. Kenta Hongo for their advice, support, and the opportunities they have given to me during my Master's year in JAIST.

The research topic on movement prediction of aperiodic time-series data was brought to me by Assistant Prof. Ichiba Tomohiro, so I would also like to thank him for introducing me to this problem and for the guidance he provided.

This journey would never have begun without the enthusiastic support and guidance from Prof. Le Hoai Bac. Thank you for leading me to JAIST and for everything.

I would like to thank everyone in Maezono and Hongo laboratory, fellow students and the laboratory staff, for helping me out whenever I run into trouble with the administrative documents or health.

Lastly, I wish to thank my parents for their never-ending support, motivation, and phone calls, and for helping me to stay connected with my family and friends at home.

Contents

List of Figures

List of Tables

Chapter 1

Introduction

1.1 Background

Time-series data is gaining popularity alongside numerical, categorical, and text data not only in terms of data sources (like finance, energy, and transportation), but also in terms of methods for analyzing and forecasting them (like frequency decomposition and methods based on historical data memorization). This makes sense as planning, organizing, and developing business strategies are greatly aided by the analysis and prediction of time-series data.

The two main approaches used in analyzing and predicting time-series data are fundamental analysis and technical analysis [3]. While fundamental analysis concentrates on examining external factors that are hard to capture from past price changes, such as the economic strategies and policies of nations and businesses, technical analysis relies entirely on historical price changes to forecast future trends

It is challenging to achieve efficient automation of basic analytical methods due to the unstructured nature of news data. As a result, academics frequently concentrate on creating techniques for technical analysis. The forecasting process can now be intelligently automated with the help of machine learning and deep learning techniques, such as Autoregressive model (1951) [4], Moving average model (2000) [5], Long short-term memory model - `LSTM` (1997) [6], and Transformers (2017) [7].

The aforementioned techniques, together with their variations, are mostly applicable to periodic time-series data, such as traffic, weather, etc. Over time, this kind of data clearly shows a seasonal or cyclical character. As a result, analysis and prediction may be done quickly and accurately. This is especially true for existing techniques that use deep neural networks to try to decompose periods [8–10]. Nevertheless, **aperiodic time-series data** (e.g., stock prices, foreign exchange rates, etc.) has been the subject of very

few investigations.

As can be seen in figure 1.1, the primary distinction between aperiodic and periodic time-series data is their lack of a distinct periodicity. In fact, because of seasonal fluctuations in electricity demand, the *Temperature oil* (target variable) attribute of the Electricity Transformer Temperature dataset (`ETT-m2`) [11] shows a very noticeable periodicity over time in figure 1.1b. In the meanwhile, a number of external factors influence the *Close price* between the US dollar and the Japanese yen (figure 1.1a). This exchange rate can be significantly impacted by recent economic news. As a result, there is no periodicity in this exchange rate.

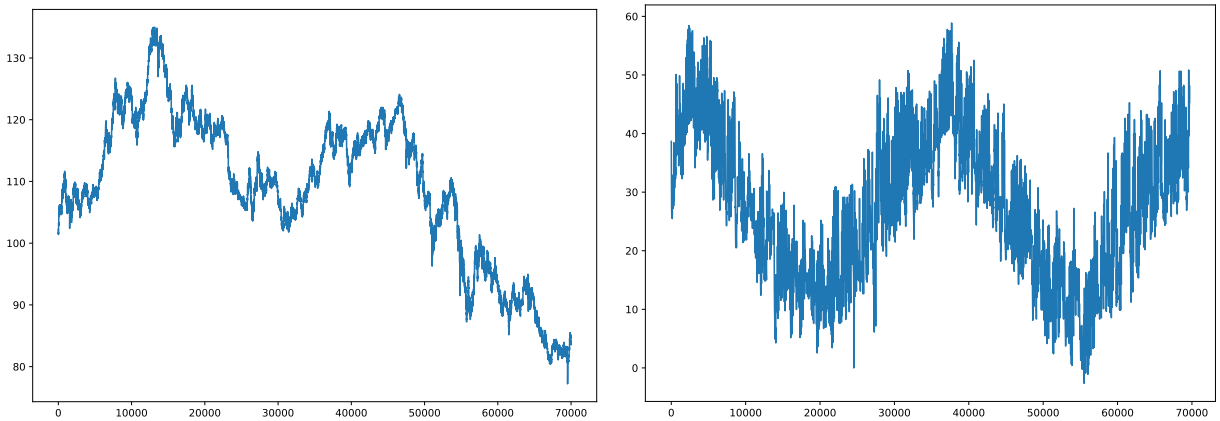

(a) Exchange ratio between USD and JPY. (b) *Oil temperature* in `ETT-m2` dataset.

Figure 1.1: 70.000 samples of aperiodic (1.1a) and periodic (1.1b) time-series dataset.

Aperiodic time-series data's primary feature is that it is heavily impacted by external factors, including production strategy and the political and economic policies of nations or businesses. This has resulted in notable modifications to the data's characteristics, which are also referred to as concept drift scenarios [12]. Mathematically, this results in aperiodic time-series data with a continuous and incredibly wide variance. Additionally, because the data no longer exhibits periodicity, it becomes extremely challenging to extract characteristics from it using a sliding window.

In conclusion, there are three primary obstacles to overcome when dealing with aperiodic time-series data: (1) External influences including politics, economy, and society have a significant impact on the data; (2) Data has a massive and non-stationary variance; and (3) Data's strong non-periodicity makes feature extraction challenging. **In this study, we focus on solving the three challenges mentioned above in the problem of trend prediction (upward or downward) on aperiodic time-series data.**

1.2 Motivation

In three aforementioned challenges, the first challenge is the most difficult to solve based on technical analysis methods because political and social information is difficult to extract through historical data of a data set. However, according to the efficient market hypothesis [13], historical data itself clearly reflects information about market fluctuations. That means, **by carefully examining the transaction history, one can completely grasp market fluctuations and forecast the future** without using political and social information. In addition, [14, 15] studies also point out the dependence between the financial indicators of a certain company and the indicators of other companies. In other words, **integrating analysis of multiple sources of information within the same domain can yield valuable analytical insights for the indicator of interest.**

When faced with the second challenge, ensemble learning is often used to mitigate the effects of variance [16–18]. Basically, ensemble learning works by splitting the data into multiple parts and assuming a fixed level of variance across these parts, then simulating that variation. This approach is reasonable because it is difficult for a single model to capture all the variability in the data over a long period of time. **By analyzing and synthesizing information from multiple sub-models, ensemble learning provides a multidimensional view of the data, which helps the overall model adapt well to strong variance changes.**

Up to now, many models have been proposed to be able to extract features on data in general and time-series data in particular. Typically, Convolutional neural network - `CNN` [19], `LSTM` [6], and attention mechanism [7,20,21] have been proposed to extract local features, remember short-term and long-term features, and emphasize vectors in the feature matrix, respectively. **By selectively using these methods, hidden constraints in aperiodic time-series data can be extracted effectively**, helping to overcome the third challenge.

On the other hand, Meta-learning (ML) algorithms are known for their ability to increase the generalization and adaptability of a model on a limited dataset [22,23]. During training, the optimization process of ML can be viewed as an efficient synthesis of models across sub-tasks (sub-datasets). Based on this ability, **a machine learning models trained by ML algorithms are expected to efficiently synthesize information from multiple data sources/time periods as well as adapt well to the continuous change of variance.**

1.3 Contributions

1.4 Outline

This work is divided into 6 chapters:

- Chapter 1 provides the research context, problem statement, challenges and motivation.
- Chapter 2 presents related works, advantages and disadvantages of each study. In addition, ML is also presented in this chapter, providing the foundation for the proposed method in Chapter 3.
- Chapter 3 presents a new approach for aperiodic time-series data based on the `LSTM`/`LSTM+CNN` feature extraction method and ML model optimization method.
- Chapter 4 sets up experiments, evaluation methods for the proposed method and baseline model.
- Chapter 5 analyzes the results achieved during the experiment.
- Chapter 6 summarizes the main contributions of the study as well as presents future development directions.

Chapter 2

Related Works

In this chapter, we analyze several approaches in handling time-series data, indicating the advantages and disadvantages of each approach. The related studies range from old methods such as ensemble model, deep feature-based approach, to recent methods which aim to decompose the input signal to frequency bands.

2.1 Ensemble models

The variance on time-series data is not constant and often varies greatly over time. This variation is often referred to as the concept of drift scenarios [12]. To increase the stability of the prediction system in the context of continuously varying data variance, instead of using a single model, the ensemble approach proposes using multiple models and combining them to generate predictions.

Instead of training a learner from training data, ensemble methods train a set of learners to solve the same problem. The general form of the ensemble model $g(\mathbf{x})$ is expressed by the aggregation of models $\{h_i, i = 1 \dots T\}$ as follows:

$$g(\mathbf{x}) = \sum_{i=1}^{T} \alpha_i h_i(\mathbf{x}), \text{ with } \sum_{i=1}^{T} \alpha_i = 1 \tag{2.1}$$

In equation 2.1 the summation operation is mentioned abstractly, referring to the process of ensemble. h_i is called the base learner. The base learner can be created from any base learning algorithm (e.g., decision tree, neural network, etc.,). Most ensemble methods use the same base learning algorithm with different training data to train the base learners. This results in base learners of the same type (i.e., the base learners are all decision trees or neural networks, etc.,).

Ensemble models are often better at generalizing than base learners because they combine weak learners, which can predict only slightly better than random, to built a strong learner, which can predict with much better accuracy. Hence, base learners are often called weak learners. Indeed, when increasing levels of noise in the data, ensemble models always give better predictions than a single model.

In addition, the computational cost of creating multiple base learners and combining them is not too large compared to building a single model because when creating a single model, we often have to create many versions of that model during tuning. This is equivalent to generating multiple base learners in the ensemble approach. The process of combining features of an ensemble model is usually not too expensive because the combination strategy is usually very simple (e.g., voting, averaging).

Based on the process of generating base learners, we refer to two main approaches to ensemble methods: `Bagging` and `Boosting` models. Where, `Bagging` generates base learners in parallel while `Boosting` generates base learners sequentially.

2.1.1 Bagging model

The main motivation of `Bagging` is based on exploiting the independence of each base learner. `Bagging` assumes that the model error can be significantly reduced by combining independent base learners. Contrary to the initial conception, the word "bagging", although referring to dividing data into bags, does not come from the word "bag" but is an abbreviation of the word "Bootstrap AGGregatING". As mentioned in the name, `Bagging` consists of two main ideas: "bootstrap" and "aggregation".

`Bagging` uses bootstrap distribution to generate different datasets for training base learners. In other words, it applies bootstrap sampling technique to obtain samples and train base learners on separate samples. Specifically, given n training data points, samples containing n data points are generated by sampling with replacement from n original data points. By repeating this process T times, T samples are generated.

During the aggregation process, `Bagging` uses voting for the classification problem and averaging for the regression problem to aggregate output from base learners. Specifically, a `Bagging` model with T base learners $\{h_i, i = 1 \dots T\}$ in the regression problem will predict instance $\mathbf{x}$ as follows:

$$\hat{y} = \frac{1}{T} \sum_{i=1}^{T} h_i(\mathbf{x}) \tag{2.2}$$

2.1.2 Boosting model

The idea of `Boosting` comes from sequentially improving the model's prediction performance on data that it previously predicted incorrectly. This improvement is done by adjusting the distribution of the data set. We will present a toy example to illustrate this idea.

Given a data set $\mathcal{D}$ drawn from the space $\mathcal{X}$. The space $\mathcal{X}$ consists of three parts $\mathcal{X}_1, \mathcal{X}_2$ and $\mathcal{X}_3$ with equal proportions. Suppose that model h_1 after training on $\mathcal{D}$ can predict well on data samples belonging to $\mathcal{X}_1, \mathcal{X}_2$ and has poor performance on data samples belonging to $\mathcal{X}_3$. At this point, we can correct the error of h_1 by training a model h_2 on the data set $\mathcal{D}'$. In which, $\mathcal{D}'$ is the calibrated dataset from $\mathcal{D}$ to emphasize the samples $x \in \mathcal{X}_3$. After training, h_2 can overcome the weakness of h_1 on the space $\mathcal{X}_3$. By combining these two models, the output model is expected to perform well on all three sub-spaces of $\mathcal{X}$. However, suppose that this model only performs well on $\mathcal{X}_1, \mathcal{X}_3$. At this point, we continue to calibrate the training dataset to obtain $\mathcal{D}''$.

In a nutshell, `Boosting` works by training base learners sequentially and then combining them to make predictions. Later learners focus on improving the errors of earlier learners.

The limitation of ensemble models lies in the process of synthesizing base learners. This process is based on two mechanisms: voting and averaging, corresponding to the classification problem and the regression problem. **It is not difficult to see that these two mechanisms are really simple and rigid. That makes the ensemble approach, although improving the generalization ability compared to training a single model, the generalization ability is not really high.**

2.2 Deep feature-based approach

2.2.1 Convolutional neural network

The starting point of Convolution neural network (`CNN`) is originated from convolution operation. Therefore, when talking about `CNN`, it is impossible not to mention convolution operation. Suppose we use a sensor to locate a moving object. This sensor returns a single value $x(t)$, representing the position of the object at time t. We can retrieve this position at any time. Unfortunately, the returned value of our device is not really accurate but noisy. Therefore, to obtain a more accurate result at a time t, we have to aggregate $x(t)$ and its previous values: $x(a), a = t-1, t-2, etc.$ In fact, the closer a is to t, the more it affects $x(t)$. Therefore, a weighting function is required to weight the values of $x(a)$.

Now, the estimated value of the object's position at time t is calculated using the function $s(t)$ as follows:

$$s(t) = \int_{a=-\infty}^{\infty} x(a)w(t-a)da \tag{2.3}$$

$$= (x * w)(t) \tag{2.4}$$

The above operation is called *convolution* operation. In discrete domains, the convolution operation works as follows:

$$(x * w)(t) = \sum_{a=-\infty}^{\infty} x(a)w(t-a) \tag{2.5}$$

The key point of this operation is to show a local relationship between the object under consideration ($x(t)$) and the objects $x(a)$ with a near t. Inspired by this, the research [19] proposed a `CNN` network, using two components input (corresponding to x) and kernel (corresponding to w) and *cross-correlation* operation instead of the traditional convolution operation. However, [19] still calls it a convolution neural network. Basically, the cross-correlation operation looks quite similar to the convolution operation except for a small change in the index of the input and kernel for convenience in implementation. Specifically, the cross-correlation operation works as follows:

$$(x * w)(t) = \sum_{a=-\infty}^{\infty} x(t+a)w(a) \tag{2.6}$$

It is worth noting that `CNN` can aggregate information not only in one dimension (in our example, the time dimension), but can also aggregate information in two dimensions (for conventional RGB or gray scale images) or three dimensions (for spectral images consisting of multiple single-shot images stacked on top of each other). Here, we present two common applications of `CNN` for one-dimensional and two-dimensional aggregation on time-series data and image data. Note that these data are discrete, so the integral sign in the original equation is replaced by a summation sign. In addition, since farther away positions/timestamps have less influence on the current position/timestamp, a commonly used assumption in `CNN` is that the influence is totally local. That is, the kernel has non-zero values within the influence range and zero values outside the influence range. It can be simply visualized the kernel as a window that slides along the direction of the data to

synthesize information.

Denote I, K as the input and kernel, respectively. For time-series data, the kernel can only slide along the time direction of the data, so the convolution operation is denoted as `Conv1D`. Suppose the data under consideration is the daily close price of a company's stock, the kernel K specifies the local influence over 5 days. At day i, the feature $F(i)$ is synthesized as follows:

$$F(i) = (I * K)(i) = \sum_{m=1}^{5} I(i+m)K(m) \tag{2.7}$$

For normal image data, K becomes a matrix that determines the influence of local pixels on the pixel under consideration and can be slid in both directions from left to right and from top to bottom. Therefore, the convolution operation is denoted as `Conv2D`. Suppose this influence is a rectangular region of size $(M \times N)$, at pixel (i, j), the feature $F(i, j)$ is synthesized as follows:

$$F(i,j) = (I * K)(i,j) = \sum_{m}^{M} \sum_{n}^{N} I(i+m, j+n)K(m,n) \tag{2.8}$$

During training, `CNN` attempts to learn a reasonable influence level to efficiently extract the spatial and temporal features of the input data. The effectiveness of `CNN` comes from two main ideas. First, based on the assumption that local features are more meaningful to the object under consideration than global features, `CNN` reduces its parameter search space from a set of parameters that interact comprehensively with all inputs to a set of parameters that interact only with local features (kernels) but are more meaningful. Suppose the neural network has m inputs and n outputs. By using a kernel of size $k \ll m$, the time complexity of the computation is reduced from $\mathcal{O}(mn)$ to $\mathcal{O}(kn)$ but the efficiency of the network is increased. Second, during learning, `CNN` uses only one kernel. This reduces the space complexity from $\mathcal{O}(mn)$ in traditional neural networks to $\mathcal{O}(k)$.

However, for time-series data in general and aperiodic time-series data in particular, the data properties at any given time depend not only on recent times but also on long-term times in the past. Therefore, `CNN` is only used as a method to support feature extraction in the process of solving problems on time-series data.

2.2.2 Recurrent Neural Network

Thay vì hoạt động trên một lướt pixel như `CNN`, Recurrent neural network (`RNN`) [24] hoạt động trên một chuỗi các giá trị $\mathbf{x}^{(1)}, \ldots, \mathbf{x}^{(\tau)}$. So với mạng mạng `FullyConnected`, `RNN` có thể mở rộng số lượng datapoint trong một chuỗi đến vô hạn mà không cần tăng kích thước của mạng. Nói cách khác, `RNN` có khả năng làm việc trên các chuỗi dài hiệu quả hơn nhiều so với mạng neural truyền thống.

Tương tự như `CNN`, `RNN` cũng sử dụng một kiến trúc mạng cho phép chia sẻ tham số. Tuy nhiên, `CNN` chia sẻ tham số trong nội bộ của một mẫu dữ liệu (cùng một kernel hoạt động trên các vùng cục bộ của một mẫu dữ liệu). `RNN` chia sẻ tham số bằng cách sử dụng cùng một bộ tham số cho các mẫu dữ liệu khác nhau. Do đó, khi input một mẫu dữ liệu vào mô hình, output của mô hình chứa các thông tin của mẫu dữ liệu này và toàn bộ các mẫu dữ liệu trước đó. Điều này khiến cho việc mở rộng mô hình và apply mô hình lên các mẫu dữ liệu có độ dài khác nhau trở nên khả thi và hiệu quả hơn.

Cụ thể, gọi hàm f là mạng `RNN`. Hàm f sử dụng bộ tham số θ để rút trích thông tin từ trạng thái $\mathbf{s}^{(t-1)}$ để tạo ra trạng thái $\mathbf{s}^{(t)}$:

$$\mathbf{s}^{(t)} = f\left(\mathbf{s}^{(t-1)}; \theta\right) \tag{2.9}$$

Lưu ý rằng, $\mathbf{s}^{(t)}$ là một abstract variable, ám chỉ thông tin hiện tại phụ thuộc vào các thông tin trong quá khứ. Đối với chuỗi có độ dài τ bất kỳ, equation 2.9 có thể được triển khai $\tau - 1$ lần để nén các thông tin trong chuỗi vào các trạng thái $\mathbf{s}^{(t)}$.

Trong các mạng `RNN` thông thường, biến trạng thái $\mathbf{s}$ được thể hiện bằng thông tin rút trích được từ mạng $\mathbf{h}$ và dữ liệu $\mathbf{x}$. Cụ thể, trạng thái hiện tại $\mathbf{h}^{(t)}$ được rút trích dựa trên trạng thái trước đó $\mathbf{h}^{(t-1)}$ (chứa thông tin về toàn bộ chuỗi trước đó) và mẫu dữ liệu hiện tại $\mathbf{x}^{(t)}$:

$$\mathbf{h}^{(t)} = f\left(\mathbf{h}^{(t-1)}, \mathbf{x}^{(t)}; \theta\right) \tag{2.10}$$

Phương trình 2.10 có thể được viết lại dưới dạng mô hình $g^{(t)}$ như sau:

$$\mathbf{h}^{(t)} = g^{(t)}\left(\mathbf{x}^{(t)}, \mathbf{x}^{(t-1)}, \ldots, \mathbf{x}^{(2)}, \mathbf{x}^{(1)}; \theta\right) \tag{2.11}$$

Từ đây, có thể thấy rằng, mô hình g không cần phải cập nhật tham số khi học từng

mẫu $x^{(t)}$ như mạng neural truyền thống. Thay vào đó, nó có thể sử dụng thông tin từ một chuỗi $\mathbf{x}^{(1)}, \ldots, \mathbf{x}^{(\tau)}$ để cập nhật tham số thông qua mô hình f. Ngoài ra, việc sử dụng mô hình f còn cải thiện khả năng tổng quát hóa của mô hình đối với những chuỗi có độ dài bất kỳ.

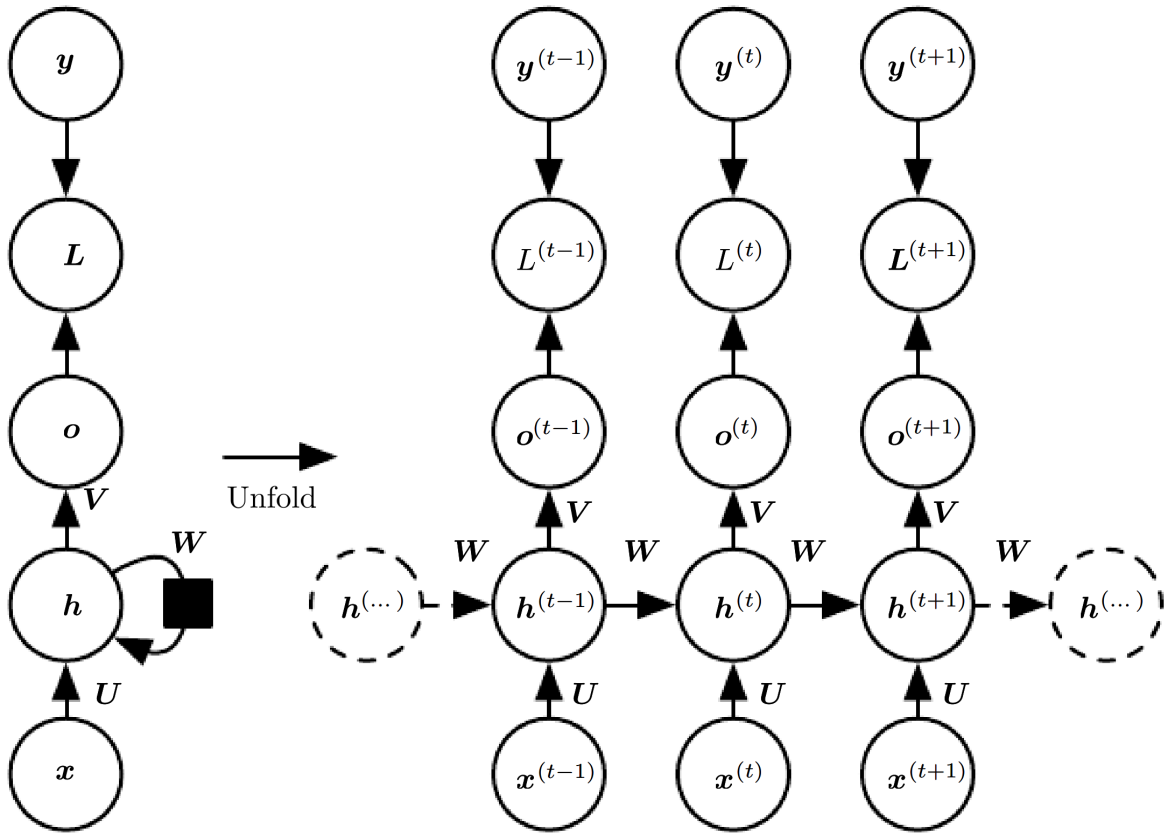

Figure 2.1: The computational graph of `RNN` in next-word prediction problem [1].

Dựa vào ý tưởng của recurrent function f trình bày ở trên, chúng ta có thể thiết kế rất nhiều kiến trúc mạng `RNN`. Tại đây, chúng tôi trình bày về một thiết kế đơn giản có đồ thị tính toán như hình 2.1. Theo đó, mạng nhận vào một chuỗi các giá trị $\mathbf{x}$ với mục tiêu ánh xạ các giá trị này vào các đầu ra $\mathbf{o}$ khớp với $\mathbf{y}$. Để thực hiện điều này, mạng sử dụng ba bộ tham số chính: $\mathbf{U}$ để ánh xạ $\mathbf{x}$ vào không gian đặc trưng ẩn; $\mathbf{W}$ để ánh xạ đặc trưng ẩn của timestamp trước vào không gian đặc trưng ẩn của timestamp sau; $\mathbf{V}$ để ánh xạ đặc trưng ẩn vào không gian chứa các giá trị đầu ra chưa chuẩn hóa ($\mathbf{o}$). Giá trị dự đoán $\hat{y}$ sau đó được tính từ $\mathbf{o}$. Cả quá trình được thể hiện như sau:

$$\mathbf{a}^{(t)} = \mathbf{b} + \mathbf{W}\mathbf{h}^{(t-1)} + \mathbf{U}\mathbf{x}^{(t)} \quad (\mathbf{b} \text{ is bias vector}) \tag{2.12}$$

$$\mathbf{h}^{(t)} = \tanh\left(\mathbf{a}^{(t)}\right) \tag{2.13}$$

$$\mathbf{o}^{(t)} = \mathbf{c} + \mathbf{V}\mathbf{h}^{(t)} \quad (\mathbf{c} \text{ is bias vector}) \tag{2.14}$$

$$\hat{y}^{(t)} = \text{softmax}\left(\mathbf{o}^{(t)}\right) \tag{2.15}$$

Độ lỗi của mô hình được tính bằng hàm `CrossEntropyLoss` (equation 2.16). Hàm lỗi này được sử dụng để cập nhật các tham số của hàm f thông qua kỹ thuật back-propagation through time.

$$L\left(\left\{\hat{y}^{(t)}\right\}_{t=1}^{\tau}, \left\{y^{(t)}\right\}_{t=1}^{\tau}\right) = \sum_{t=1}^{\tau} L^{(t)}\left(\hat{y}^{(t)}, y^{(t)}\right) \tag{2.16}$$

Trong quá trình forward và backward, các bước tính toán được thực hiện tuần tự vì phải tuân theo trình tự thời gian. Do đó, time complexity của `RNN` là $\mathcal{O}(\tau)$. Vì phải lưu trữ các giá trị đạo hàm sau để tính toán các giá trị đạo hàm trước đó (theo Chain rule), space complexity của thuật toán cũng là $\mathcal{O}(\tau)$. Do đó, đối với các chuỗi dài, chi phí tính toán có thể sẽ rất lớn.

2.2.3 Long Short-Term Memory

Khi làm việc trên các chuỗi dài, `RNN` rất dễ mắc phải vấn đề *vanishing gradient* hoặc *exploding gradient*. Thật vậy, quá trình huấn luyện của `RNN` đòi hỏi việc sử dụng Chain rule cho tất cả các trạng thái từ $t = \tau$ đến $t = 1$. Quá trình này bao gồm rất nhiều phép nhân ma trận và vector. Do đó, nếu các phần tử trong ma trận hoặc vector đó nhỏ hơn 1, đạo hàm theo thời gian sẽ hội tụ về 0. Ngược lại, nếu các phần tử đó lớn hơn 1, theo thời gian, đạo hàm sẽ tiến đến vô cùng.

2.3 Frequency decomposition approach

2.3.1 A transformer-based method

2.3.2 NHITS

Neural Hierarchical Interpolation for Time Series Forecasting (`NHITS`) [2] is designed to target the prediction of long-horizon time-series data by decomposing the input signal into discrete frequency bands. The structure of `NHITS` consists of S stacks, each stack consisting of B consecutive blocks. At each block, a Multi-layer perceptron (`MLP`) uses historical data to predict itself and future data (see figure 2.2).

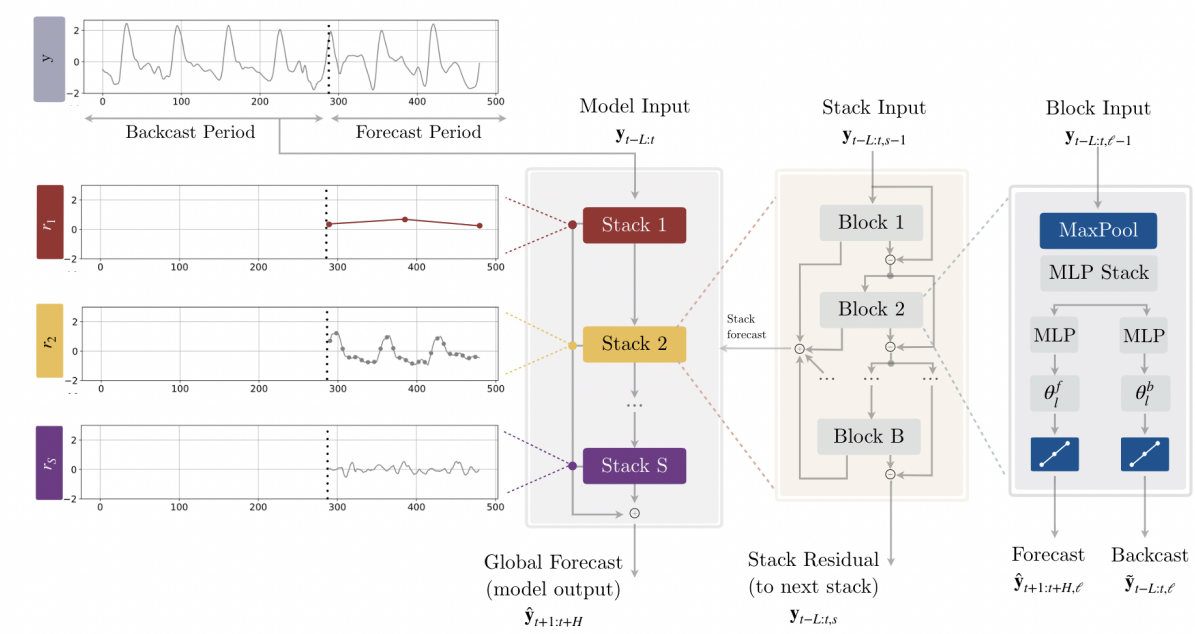

Figure 2.2: `NHITS` architecture [2].

Specifically, at block l, with L historical samples ($\mathbf{y}_{t-L:t,l-1}$), an `MLP` use three techniques, Multi-rate signal sampling, Non-linear regression, and Hierarchical interpolation, respectively, to regress past data and predict future data.

Multi-rate signal sampling. `MaxPool` layer with kernel size l compresses the original data into $\mathbf{y}^{(p)}_{t-L:t,l}$ (equation 2.17). When k_l is large, the amount of data considered in a sliding window is also large, the network will pay more attention to input signal with long wavelengths (low frequencies). When k_l is small, the obtained features are of short wavelengths (high frequencies). By using `MaxPool` layer, `MLP` will be able to work on a certain frequency band, which helps to increase the efficiency of frequency decomposition. Not only stopping at frequency band decomposition, `MaxPool` essentially reduces the size of the input signal, helping to save memory during training and inference.

$$\mathbf{y}^{(p)}_{t-L:t,l} = \mathbf{MaxPool}\left(\mathbf{y}_{t-L:t,l-1}, k_l\right) \tag{2.17}$$

Non-linear regression. After compressing the data, `NHITS` learns the interpolation coefficients using stacked perceptron layers with a nonlinear activation function (`FullyConnected`). The goal of `FullyConnected` is to generate the vectors θ^f_l, θ^b_l (equation 2.20). These are the two interpolation vectors forecast and backcast, which are used to aggregate the output values of block l using the interpolation function $g(\cdot)$. In which, θ^f_l is used to forecast future values and θ^b_l is used to regress the input values.

$$\theta^b_l = \mathbf{FullyConnected}^b\left(\mathbf{y}^{(p)}_{t-L:t,l}\right) \tag{2.18}$$

$$\theta^f_l = \mathbf{FullyConnected}^f\left(\mathbf{y}^{(p)}_{t-L:t,l}\right) \tag{2.19}$$

$$\tag{2.20}$$

Hierarchical interpolation. To forecast H future values, a conventional neural network must redesign the number of output neurons. For transformer models, to increase the number of output samples, it is necessary to increase the number of input samples so that the cross-attention layers can work effectively. This makes the traditional training process very resource-consuming when there is a need to predict large H. `NHITS` solves this problem by using an interpolation equation with pre-prepared interpolation coefficients in the **Non-linear regression** step (equation 2.22). The dimensionality of the interpolation coefficients in each stack is determined by the expressiveness ratio r_l: $|\theta_l| = \lceil r_l H \rceil$. Typically, the expressiveness ratio will be very small in the first stacks and gradually increase towards the end. Accordingly, the stacks can simulate frequencies from low to high. In addition, by using the interpolation function, `NHITS` does not require too much hardware to train the neural network in the case of large H.

$$\hat{\mathbf{y}}_{t-L:t,l} = g\left(\theta^b_l\right) \tag{2.21}$$

$$\hat{\mathbf{y}}_{t+1:t+H,l} = g\left(\theta^f_l\right) \tag{2.22}$$

The output of block l is the forecast value $\hat{\mathbf{y}}_{t+1:t+H,l}$ and the backcast value $\hat{\mathbf{y}}_{t-L:t,l}$. Input of block $l+1$ is the difference between its backcast and its output (2.23).

$$\mathbf{y}_{t-L:t,l+1} = \mathbf{y}_{t-L:t,l-1} - \hat{\mathbf{y}}_{t-L:t,l} \tag{2.23}$$

Summing the forecast values of B blocks as in equation 2.24, we get the forecast value of a stack. Finally, summing the forecast values of the stacks as in equation 2.25, we get the predicted forecast value of the entire network.

$$\hat{\mathbf{y}}^{s}_{t+1:t+H} = \sum_{l=1}^{B} \hat{\mathbf{y}}_{t+1:t+H,l} \tag{2.24}$$

$$\hat{\mathbf{y}}_{t+1:t+H} = \sum_{s=1}^{S} \hat{\mathbf{y}}^{s}_{t+1:t+H} \tag{2.25}$$

By concatenating stacks, each receiving the remainder of the previous stack, **the above architecture is expected to decompose the data into different frequency bands (weekly, daily, even hourly)**. In practice, `NHITS` performs very well for highly periodic datasets such as electricity consumption, weather, traffic. **However, we are aiming for an aperiodic time-series dataset, which has very low, or even non-existent, periodicity**. This poses a huge challenge for `NHITS`.

2.4 Optimization-based Meta-learning

Meta-learning (ML) is a training method that allows a learning model to gain experience by performing many different tasks in the same task distribution. This equips the machine learning model with the ability to generalize highly and adapt quickly to new tasks after only a few training steps with limited training data [22, 23]. With this ability, ML is widely used in tasks that require the ability to fast adapt to new data (e.g. personalization of learning models [25–27], domain adaptation in online learning [**?**, 28]).

For the traditional learning model training method, we train the prediction model $\hat{y} = f_\theta(\mathbf{x})$ on the dataset $\mathcal{D}_t = \{(\mathbf{x}_i, y_i)\}$ of task t. Denote $\mathcal{L}$ is the error function, ϕ is the prior knowledge, the goal of the training process is to minimize the error function on the dataset $\mathcal{D}$ by finding the parameter θ that satisfies:

$$\theta^* = \arg\min_{\theta} \mathcal{L}(\mathcal{D}_t; \theta, \phi) \tag{2.26}$$

The ML approach is to try to learn a good prior knowledge ϕ. This is achieved by

learning a task distribution $\mathcal{T}$ [22]. Once a good prior knowledge is learned, it can be used for new tasks in the same task distribution $\mathcal{T}$. Mathematically, denote $\mathcal{L}(\mathcal{D}_t, \phi)$ is the error function that represents the effectiveness of using ϕ in training the model on task T, the ML goal is expressed as follows:

$$\min_{\phi} \mathop{\mathbb{E}}_{t \sim \mathcal{T}} \mathcal{L}(\mathcal{D}_t, \phi) \tag{2.27}$$

2.4.1 Model-Agnostic Meta-Learning (MAML)

For the optimization-based approach, a basic ML algorithm, typically `MAML`, is learned on multiple tasks t drawn from the same task distribution $\mathcal{T}$ [22]. The data for each task is divided into a support set $\mathcal{D}_t^{support}$ (usually small, around 20%) and a query set $\mathcal{D}_t^{query}$. During the learning process, inner and outer optimization are performed alternately. The goal of inner optimization is to attempt to solve task t by finding an optimal set of parameters θ_t^* on the support set via ϕ:

$$\theta_t^* = \theta_t(\phi) = \arg\min_{\theta} \mathcal{L}_t^{task} \left(\phi, \mathcal{D}_t^{support}\right) \tag{2.28}$$

Where, ϕ is the result of the outer optimization process, which acts as the initial value of θ_t. $\mathcal{L}_t^{task}$ is the error function of the model on the support set of task t.

The goal of outer optimization is to find the optimal prior knowledge ϕ^*, which makes learning a new task in the distribution $\mathcal{T}$ fast and efficient. Specifically, the algorithm uses the optimal parameter sets θ_t^* to perform on the corresponding query set. The errors of the entire model are then aggregated to perform the outer optimization process:

$$\begin{aligned} \phi^* &= \arg\min_{\phi} \sum_t \mathcal{L}_t^{meta} \left(\theta_t^*, \mathcal{D}_t^{query}\right) \\ &= \arg\min_{\phi} \sum_t \mathcal{L}_t^{meta} \left(\theta_t(\phi), \mathcal{D}_t^{query}\right) \end{aligned} \tag{2.29}$$

By performing the above training method, the ϕ^* model will have a high level of generalization across different tasks, and can quickly respond to a new task after only a few training steps.

In the inference phase, the initial values for the model parameters are assigned ϕ^*. The model is then adapted quickly to the support set and performed on the query set. The results on the query set are the model output.

2.4.2 Meta-SGD

As for the `Meta-SGD` algorithm, study [29] shows that using a small, fixed local learning rate over time or a decreasing local learning rate over time is only suitable for the context of training a model with a large dataset over a long period of time. In the context of limited labeled data but the model needs to adapt quickly to new data sets, such hyperparameter selection method is no longer suitable.

The [29] study also proposes a new approach that allows self-tuning and local hyperparameter optimization. Accordingly, in addition to optimizing prior knowledge (ω), the algorithm also considers the inner learning rate α as an learnable parameter. By initializing α as a matrix of the same size as θ, the algorithm aims to update both the direction and the learning rate for each weight element in θ by adjusting α at the outer optimization. Subsequently, tasks use α by multiplying (element-wise product) this quantity by the local error function derivative. Accordingly, `Meta-SGD` not only makes learning models adapt quickly on local data sets, but also contributes greatly to personalizing the learning model for each task.

One disadvantage of optimization-based ML method lies in solving equation 2.29 which requires massive overhead to compute and maintain a Hessian matrix. Even so, ML algorithms still achieve a high accuracy in handling many problem in which the quick adaptation or effective model synthesis are required.

Chapter 3

Methodology

We propose `Temporal-ML`, a ML-based method which consists of two main components that work in parallel: (1) - Temporal feature extraction; (2) - Models' parameter synthesis. The overview of the method is illustrated in figure 3.1 and the detail is presented in algorithm 1. In the *Temporal feature extraction* section, we propose to use the features extracted from `BiLSTM` network. In the *Effective synthesis of model's parameters* section, `MAML` is utilized to synthesize the parameters of the models.

Due to the contribution of `BiLSTM` features, we expect to effectively extract hidden temporal features from aperiodic data. By using `MAML` in the weight aggregation process, the proposed method is expected to be a reasonable and effective alternative to traditional ensemble models in effectively synthesizing external factors, minimizing the impact of variance variation, and efficiency capturing hidden long-term dependencies in the past.

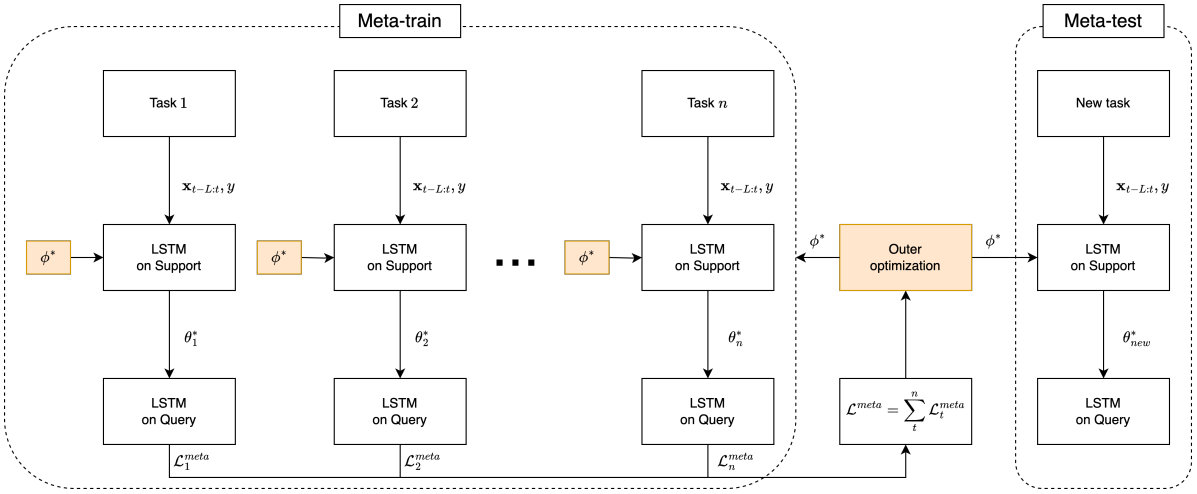

Figure 3.1: The full-flow of meta-training and meta-testing on multi-fx data. Each currency pair is regarded as a task.

Algorithm 1 Temporal-ML

Initialize ϕ_0

for round $r = 1, 2, ...$ **do** ▷ Outer loop

  Sample a subset T_r of m tasks

  for task $t \in T_r$ **do** ▷ Inner loop

    Initialize inner weight $\theta_t^{(0)} \leftarrow \phi_{r-1}$

    Forward: For all data point $\mathbf{x}$ in $\mathcal{D}_t^{support}$

$$\begin{aligned} \mathbf{x}' &= \textbf{FullyConnected}\left(\mathbf{x}\right) \\ \mathbf{h}_{LSTM} &= \textbf{BiLSTM}\left(\mathbf{x}'\right) \\ \hat{y} &= \textbf{FullyConnected}\left(\mathbf{h}_{LSTM}\right) \end{aligned}$$

    Backward and aggregate meta loss: ▷ Inner optimization

$$\begin{aligned} &\mathcal{L}_t^{task}\left(\theta_t^{(e-1)}, \mathcal{D}_t^{support}\right) = \textbf{CrossEntropyLoss}\left(\mathbf{y}, \hat{\mathbf{y}}\right) \\ &\theta_t^{(e)} \leftarrow \theta_t^{(e-1)} - \alpha \nabla_\theta \mathcal{L}_t^{task}\left(\theta_t^{(e-1)}, \mathcal{D}_t^{support}\right) \\ &\mathcal{L}^{meta} \leftarrow \mathcal{L}^{meta} + \mathcal{L}_t^{meta}\left(\theta_t^{(e)}, \mathcal{D}_t^{query}\right) \end{aligned}$$

  Outer optimization at round r: ▷ Outer optimization

$$\phi_{r+1} \leftarrow \phi_r - \beta \nabla_\phi \mathcal{L}^{meta}$$

3.1 Data preparation

`Temporal-ML` uses ML algorithms to train the model. Therefore, the data needs to be reorganized so that the ML algorithms can work. In case the data includes many different datasets belonging to the same field, each dataset will be considered a task. **The goal of using multiple datasets of the same domain is to utilize the corelation between them** as indicated in study [14, 15]. In case the data includes a single dataset, it is necessary to divide this dataset into subsets corresponding to separate tasks. **In this way, we aim to enhance the learning of information about external factor reflected in single dataset** [13]. In summary, the prepared dataset includes n tasks: $\mathcal{D} = \{\mathcal{D}_t\}_{t=1}^{n}$. The data at each task is divided into support and query sets: $\mathcal{D}_t = \left\{\mathcal{D}_t^{support}, \mathcal{D}_t^{query}\right\}$.

A data sample consists of pairs of values $(\mathbf{x}_{t-L:t}, y)$. In which, $\mathbf{x}_{t-L:t}$ includes L historical values from time t back; $y \in \{0, 1\}$ is the data label, showing the decreasing or increasing trend of the data sample x_{t+1} compared to x_t. Depending on each problem and

the implementation, the elements in $\mathbf{x}_{t-L:t}$ can be a matrix or a vector. For example, for stock data, $\mathbf{x}_{t-L:t}$ can contain L vectors $\vec{x}_i$ = (open, low, high, close) or can be a vector of close price values only.

3.2 Temporal feature extraction

Feature extraction is performed using `BiLSTM`. Specifically, each element in the matrix $\mathbf{x}_{t-L:t}$ (abbreviated as $\mathbf{x}$) is passed through a `FullyConnected` layer whose output is larger than the dimension of $\vec{x}_i, i \in [t-L, t]$ to obtain vector $\vec{x}'_i$ (equation 3.1). Accordingly, the data characteristics are expressed more deeply and clearly. These features are then passed through the `BiLSTM` network (equation 3.2) to selectively extract long-term temporal dependencies ($\mathbf{h}_{BiLSTM}$). At the end, $\mathbf{h}_{BiLSTM}$ is passed through a classification head of the neural network (equation 3.3) to predict the label of $\mathbf{x}$.

$$\mathbf{x}' = \mathbf{FullyConnected}\,(\mathbf{x}) \tag{3.1}$$

$$\mathbf{h}_{BiLSTM} = \mathbf{BiLSTM}\,(\mathbf{x}') \tag{3.2}$$

$$\hat{y} = \mathbf{FullyConnected}\,(\mathbf{h}_{BiLSTM}) \tag{3.3}$$

`LSTM` and `BiLSTM` both maintain cell-state values to selectively store temporal dependencies, as well as to mitigate the vanishing gradient problem during training. Therefore, these networks are well suited for solving time-series data problems. However, for long input sequences, `LSTM` has difficulty in exploiting global context (the entire input sequence) and often faces the problem of local information loss (the further the input, the easier it is to forget). These two problems are effectively solved by `BiLSTM`. With the ability to extract and synthesize information from both sides of the input sequence, `BiLSTM` **can capture the entire context with minimal information loss for distant inputs. In the context of the movement prediction of aperiodic time-series data problem,** `BiLSTM` **is expected to successfully capture continuous value variation as well as not miss important information at distant inputs**. Therefore, it is a more reasonable choice in extracting temporal constraints.

3.3 Effective aggregation of models' parameters

We use `MAML` as presented in the algorithm 1 to train and aggregate the weights of the models of all tasks via the `CrossEntropyLoss` (equation 3.4).

$$\mathcal{L}(\mathbf{y}, \hat{\mathbf{y}}) = \frac{1}{\dim(\mathbf{y})} \sum_{i=1}^{\dim(\mathbf{y})} (\mathbf{y}_i \log \hat{\mathbf{y}}_i) + (1 - \mathbf{y}_i) \log (1 - \hat{\mathbf{y}}_i) \tag{3.4}$$

As mentioned in section 2.4, parameter optimization in the ML approach is to solve the two equations 2.28 and 2.29 using optimization methods on the support set and query set. Specifically, the optimization process includes many global steps (outer optimization), performed on all tasks participating in training. Each global step includes many local steps (inner optimization) performed on each individual task. At global step r, the eth local optimization process on the support set of task t proceeds as follows:

$$\begin{cases} \theta_t^{(0)} & = \phi_{r-1} \\ \theta_t^{(e)} & = \theta_t^{(e-1)} - \alpha \nabla_\theta \mathcal{L}_t^{task} \left(\theta_t^{(e-1)}, \mathcal{D}_t^{support} \right) \end{cases} \tag{3.5}$$

In which, ϕ_{r-1} is the result of the $r-1$ outer optimization process, α is the inner learning rate, $\mathcal{L}_t^{task}$ evaluates the use of $\theta_t^{(e-1)}$ on $\mathcal{D}_t^{support}$.

Next, the outer optimization process is performed by aggregating the losses on the query set of the tasks and optimizing on it (equation 3.6).

$$\begin{cases} \phi_0 = \text{Random Initialization} \\ \phi_r = \phi_{r-1} - \beta \nabla_\phi \sum_{t=1}^{n} \mathcal{L}_t^{meta} \left(\theta_t^*(\phi), \mathcal{D}_t^{query} \right) \end{cases} \tag{3.6}$$

Where, β is the outer learning rate, $\theta_t^*(\phi)$ is the local optimized weight obtained from equation 3.5, $\mathcal{L}_t^{meta}$ evaluates the use of $\theta_t^*(\phi)$ on $\mathcal{D}_t^{query}$.

Assuming the algorithm runs E steps in inner optimization, the derivative quantity at equation 3.6 is rewritten as follows (the notations of dataset are removed):

$$
\begin{aligned}
\nabla_\phi \sum_{t=1}^{n} \mathcal{L}_t^{meta}\left(\theta_t^*(\phi)\right) =& \nabla_\phi \sum_{t=1}^{n} \mathcal{L}_t^{meta}\left(\theta_t - \alpha \nabla_\theta \mathcal{L}_t^{task}\left(\theta_t\right)\right) \\
=& \sum_{t=1}^{n} \frac{\partial \mathcal{L}_t^{meta}\left(\theta_t^{(E)}\right)}{\partial \theta_t^{(E)}} \frac{\partial \theta_t^{(E)}}{\partial \phi} \\
=& \sum_{t=1}^{n} \nabla_\theta \mathcal{L}_t^{meta}\left(\theta_t^{(E)}\right) \prod_{j=0}^{E-1} \left[\mathbb{I} - \alpha \nabla_\theta^2 \mathcal{L}_t^{task}\left(\theta_t^{(j)}\right)\right]
\end{aligned} \tag{3.7}
$$

The presence of the product of second order derivatives in the equation 3.7 makes the derivation process complicated because it requires a lot of overhead to maintain Hessian matrices. Therefore, the number of computational steps to find θ^* needs to be limited. In practice, methods using ML [25–27, 29, 30] often choose $E \in [1, 5]$.

Hybrid ensemble models have been widely used in time-series processing problems and have been experimentally proven to be more accurate than standard time-series models because they can synthesize the strengths of many sub-models [3]. However, current ensemble model synthesis forms are still very rigid because they can only synthesize based on the final results (e.g. voting mechanism of bagging models) and semi-final results (e.g. stacking models). **From the perspective of ensemble models, equation 3.6 can be considered an optimization-based method of synthesizing sub-models, which helps to take advantage of the feature extraction capabilities of each model. Moreover, equation 3.6 produces a fast-adaptive model which is extremely suitable for the context of unstable variance in data**. In other words, the synthesized model can quickly adapt to data with new variance as well as extract features at a deeper level, which significantly improves the prediction ability compared to traditional ensemble models.

Chapter 4

Numerical Experiment

Chapter 4 describes experiments to evaluate `Temporal-ML` and compare it with `NHITS` on large and popular datasets. The experiments are performed on aperiodic data consisting of a single dataset and aperiodic data consisting of multiple datasets to verify the ability to extract market information as well as the ability to aggregate information from multiple sources. Periodic data is also used to increase the objectivity of the evaluations. In addition, we perform the removal/replacement of components of `Temporal-ML` to analyze the capabilities of these components in detail.

4.1 Dataset description

Foreign exchange in particular and financial indices in general are typical data types for aperiodic time-series data. Therefore, we choose this type of data to test the model. Specifically, we configure two datasets using foreign exchange data. `USD/JPY` dataset consists of only data of the exchange rate between US dollar and Japanese yen. The data is sampled hourly from 2000 to 2024, including the attributes of open, low, high, and close price. **By carefully examining the transaction history as well as effectively aggregating data characteristics, we expect to forecast the movement of price without utilizing external information.**

`multi-fx` dataset consists of 60 currency pairs made of 18 countries: Australia, Canada, Switzerland, Denmark, EU, United Kingdom, Hong Kong, Iceland, Japan, Norway, New Zealand, Singapore, Sweden, Turkey, United States, Mexico, China, South Africa. The data has similar attributes to `USD/JPY` and sampled daily from 2014 to 2024. **By integrating analysis of multiple sources of information in the domain of FX, we expect to obtain valuable analytical insights for the indicator of interest.**

In addition, we used two periodic datasets: Electricity Transformer Temperature

(ETT-m2) [11] and Weather (WTH) [31]. ETT-m2 dataset consists of 7 data fields, measuring the parameters of a transformer in a province of China every 15 minutes from July 2016 to July 2018. WTH dataset consists of 12 data fields, recording the weather parameters at the Weather Station of the Max Planck Biogeochemistry Institute in Jena, Germany every 10 minutes in 2020. These two datasets exhibit very strong periodicity, which NHITS has been very successful in predicting. Experiments on them provide a more comprehensive comparison of the proposed method's capabilities against NHITS.

4.2 Temporal-ML

4.2.1 Data pre-processing

As mentioned in section 3.1, to use ML, the datasets need to be structured into separate tasks. In each task, the support set accounts for 20% of the data, the query set accounts for 80% of the data. For multi-fx, each currency pair is divided into 2 datasets, corresponding to 2 tasks. Therefore, 60 currency pairs form 120 tasks. For the remaining datasets, each dataset is divided into time series, each corresponding to a task. During the whole process, 50% of the tasks are used in the meta-training process, 25% of the tasks are used in the meta-validation process, and the remaining tasks are used in meta-testing. Statistics for tasks by dataset are presented in table 4.1.

Table 4.1: Statistics on datasets.

Dataset	Attribute	Task	Sample	Sample/Task
USD/JPY	4	60	150,175	2,503
multi-fx	4	120	154,440	1,287
ETT-m2	7	48	69,680	1,452
WTH	12	40	35,064	877

Since the datasets are all time-series, the training data should not reveal any information about the future. Therefore, the 120 tasks of the multi-fx dataset are divided as shown in 4.1a. For the remaining datasets, the data used in the training, testing, and validation must be in chronological order from past to future.

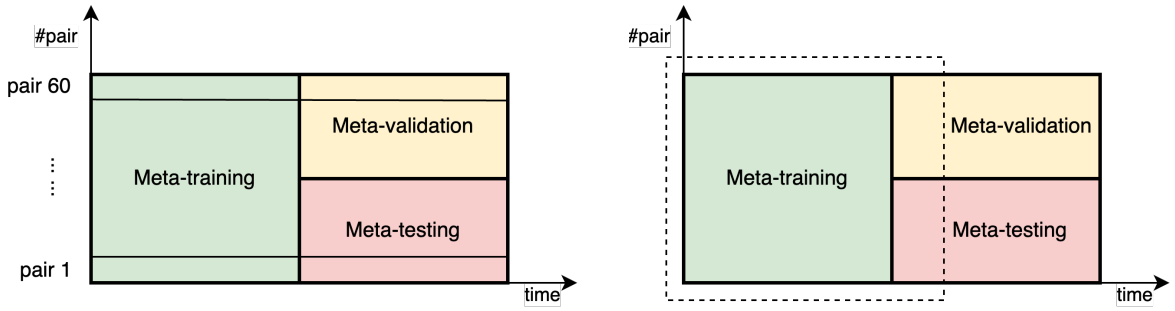

(a) (b)

Figure 4.1: (a): Splitting data for `multi-fx`. (b): Pre-process for `multi-fx` (dash line rectangle accounts for all training and 20% data of validation and testing tasks).

The `z-score` preprocessing is then performed on the entire training data and the support sets of the test and validation data for each currency pair (see figure 4.1b) since these are known data. Specifically, the preprocessing of attribute X is performed as follows:

$$\mu_X = \frac{1}{n}\sum_{i=1}^{n} x_i \quad (n \text{ là số mẫu của thuộc tính } X) \tag{4.1}$$

$$\sigma_X = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_i - \mu_X)^2} \tag{4.2}$$

$$X_{new} = \frac{X - \mu_X}{\sigma_X} \tag{4.3}$$

μ_X and σ_X obtained from the equations 4.1 and 4.2 are used to normalize the attribute X in the query set of the meta-validation and meta-testing processes.

4.2.2 Metric evaluation

The study uses *Accuracy, Precision, Recall*, and *F1-score* to evaluate the models (equations 4.4, 4.5, 4.6, 4.7). In which, *Accuracy* is used to calculate the ratio between the number of correctly classified samples and the total number of predicted samples, *Precision* measures the confidence level of the model when it labels a data sample, *Recall* tests the rate of misclassified data samples of a classifier, *F1-score* checks the level of bias of the model on major labels by taking the harmonic average over *Precision* and *Recall*.

$$acc = \frac{TP + TN}{TP + FP + TN + FN} \tag{4.4}$$

$$P = \frac{TP}{TP + FP} \tag{4.5}$$

$$R = \frac{TP}{TP + FN} \tag{4.6}$$

$$F1 = \frac{2PR}{P + R} \tag{4.7}$$

$$\tag{4.8}$$

Where, TP, TN, FP, FN are the number of *true_positive, true_negative, false_positive, false_negative*, respectively.

Suppose the `Temporal-ML` algorithm is evaluated on a dataset $\mathcal{D}$ consisting of a attributes and divided into n tasks. The evaluation is performed by letting the model predict the movement of each attribute with all attributes as input, then performing two aggregation steps: (1) - Aggregation on tasks; (2) - Aggregation on attributes. This evaluation process is designed based on [2].

Aggregation on tasks. Consider metric m when the model predicts any attribute k ($1 \leq k \leq a$). After predicting attribute k, we obtain n values: $\{m_1^{(k)}, \ldots, m_n^{(k)}\}$. The process of synthesizing metrics m of n tasks is performed as follows:

$$\bar{m}^{(k)} = \frac{1}{n} \sum_{i=1}^{n} m_i^{(k)} \tag{4.9}$$

$$s_m^{(k)} = \sqrt{\frac{1}{n} \sum_{i=1}^{n} (m_i^{(k)} - \bar{m}^{(k)})^2} \tag{4.10}$$

Aggregation on attributes. The model predicts all a attributes and obtains a metrics: $\left\{ \left(\bar{m}^{(k)} \pm s_m^{(k)} \right) \right\}_{k=1}^{a}$. The process of synthesizing metric m of a attributes is as follows:

$$\bar{m} = \frac{1}{a} \sum_{k=1}^{a} \bar{m}^{(k)} \tag{4.11}$$

$$s_m = \sqrt{\frac{1}{a} \sum_{k=1}^{a} (s_m^{(k)})^2} \tag{4.12}$$

4.2.3 Fine-tuning

In our implementation, we use a `FullyConnected` layer of 16 units with a `ReLU` activation function to represent deeper and more explicit features. This feature is then passed to a `BiLSTM` block. The `BiLSTM` block consists of 32 hidden units, the last two outputs of which are concatenated to form a final vector. This vector is then passed through a binary classification layer with a `Sigmoid` activation function.

Table 4.2: Search space for fine-tuning our method.

Hyper-parameter	Seach space
Inner batch size (samples/batch)	{32}
Inner training step	{3}
Outer batch size (tasks/batch)	{5}
Outer training step	{100}
Lookback window	{10, 20, 30}
Inner learning rate	{0.001, 0.00325, 0.0055, 0.00775, 0.01}
Outer learning rate	{0.001, 0.00325, 0.0055, 0.00775, 0.01}

The fine-tuning process of ML algorithms involves many hyper-parameters such as inner batch size, outer batch size, inner training step, outer training step,... To make fine-tuning easy, we fix most of the parameters and only fine-tune the size of lookback window, inner and outer learning rate. Details are presented in table 4.2.

4.3 Baseline model

4.3.1 Data pre-processing

This study uses the `NHITS` algorithm (AAAI 2023) as the baseline model. `NHITS` uses the entire set of attributes to predict the next trend for an attribute in a dataset. The algorithm aims to decompose the frequency bands and combine them to predict the future. For the `USD/JPY`, `ETT-m2`, and `WTH` datasets, the data in each set is divided into a training set, a validation set, and a test set with a ratio of 6:2:2, respectively.

We preprocess the training data with `z-score` as mentioned in subsection 4.2.1. Then, μ_X and σ_X obtained from 4.1 and 4.2 equations are used to normalize the attribute X in the validation set during tuning. Once the best hyper-parameters are selected, the training and validation data are renormalized from scratch, and then trained with the best set of hyper-parameters to predict the test set.

For the `multi-fx` dataset, since `NHITS` does not have a mechanism to aggregate models across different datasets, we repeat the training process (training, tuning, testing on 60%, 20%, 20% of the data, respectively) for each currency pair, then aggregate metrics across currency pairs to obtain the final evaluation.

In addition, a stochastic prediction model is also used for comparison. The stochastic model generates predicted values of 0 and 1 according to a uniform distribution. The process of synthesizing metrics of this model is similar to `NHITS`.

4.3.2 Metric evaluation

`NHITS` also uses similar metrics to `Temporal-ML` and is evaluated on the dataset $\mathcal{D}$ with a attributes and must perform predictions on each attribute. Considering metric m, after predicting attribute k, we obtain a values: $\{m_1^{(k)}, \ldots, m_a^{(k)}\}$. The process of synthesizing metric m of a attributes is performed as follows:

$$\bar{m} = \frac{1}{a} \sum_{k=1}^{a} m^{(k)}$$

$$s_m = \sqrt{\frac{1}{a} \sum_{i=1}^{n} (m^{(k)} - \bar{m})^2}$$

As mentioned, `NHITS` does not have a mechanism for model aggregation when testing on `multi-fx` data. Therefore, we test `NHITS` on each currency pair in `multi-fx` and aggregate metrics like `Temporal-ML`.

Table 4.3: Search space for fine-tuning NHITS.

Hyper-parameter	Seach space
Random seed	{1}
Number of stacks	{3}
Number of blocks in each stack	{1}
Activation function	{ReLU}
Batch size	{256}
Epoch	{500}
Lookback window	{10, 20, 30}
Pooling kernel	{[2,2,2], [4,4,4], [8,8,8], [8,4,1], [16,8,1]}
Stacks' coefficients	{[168,24,1], [24,12,1], [180,60,1],[40,20,1], [64,8,1]}
Number of MLP layers	{1,2}
Learning rate	{0.001, 0.00325, 0.0055, 0.00775, 0.01}

4.3.3 Fine-tuning

We rely on [2] to define the search space (table 4.3) for parameter fine-tuning, as well as to fine-tune the model architecture. For parameters not mentioned in the table, we use the default values of the `NHITS` implementation in the `NeuralForecast` library [32]. The best results of fine-tuning process are selected and reported in this study.

4.4 Fairness in evaluation

Let m be the number of data samples in each task, the total data of training, validating, and testing is: mn. For `NHITS`, the model is trained, validated, and tested on 60%, 20%, 20% of the data, respectively:

$$\begin{aligned} \text{Train: } & 0.6mn \\ \text{Validation: } & 0.2mn \\ \text{Testing: } & 0.2mn \end{aligned}$$

For `Temporal-ML`, the knowledge enrichment process for the model uses the entire training data and the support set of the testing/validation data. The testing/validation process is performed on the query set:

$$\begin{aligned} \text{Train: } & 0.5mn + 20\% \left(\frac{m}{2}n\right) = 0.6mn \\ \text{Validation: } & 80\% \left(\frac{m}{2}\frac{n}{2}\right) = 0.2mn \\ \text{Testing: } & 80\% \left(\frac{m}{2}\frac{n}{2}\right) = 0.2mn \end{aligned}$$

Therefore, with the above data division, we achieve fairness in the number of data samples during testing.

4.5 Ablation experiment

We evaluate each component in `Temporal-ML` as well as the choice of temporal feature extraction method by removing or replacing them from the algorithm and compare the results with the original algorithm. Specifically, we conduct experiments on two groups of algorithms: (1) - Model without `BiLSTM`; (2) - Model without ML. Regarding the eval-

uation of these models, ML-based models are evaluated as `Temporal-ML`, the remaining models are evaluated as `NHITS`.

4.5.1 Model without BiLSTM

We study the temporal feature extraction ability of the algorithms by replacing `BiLSTM` in `Temporal-ML` with `BiLSTM+CNN`, `Transformer` algorithms [7]. **The goal of replacing `BiLSTM` with `BiLSTM+CNN` is to test the local feature extraction ability of the extractor** by combining the features of `BiLSTM` and `CNN` then concatenating them and performing classification (equations 3.2, 4.13–4.15).

$$\mathbf{h}_{CNN} = \textbf{Convolution1D}\left(\mathbf{x}'\right) \tag{4.13}$$

$$\mathbf{h} = \textbf{Concatenate}\left(\mathbf{h}_{LSTM}, \mathbf{h}_{CNN}\right) \tag{4.14}$$

$$\hat{y} = \textbf{FullyConnected}\left(\mathbf{h}\right) \tag{4.15}$$

`Transformer` is composed of two encoders. Each encoder uses three attention heads, and the key vector dimension is 256. The `FeedForward` part of the encoder uses two `Convolution1D` layers and one `LayerNormalization`. After stacking the two encoder layers, the feature matrix is passed through a `Flatten` layer and then fed into the classification head. `Transformer` is a widely used and excellent performing neural network. **The goal of using this network is to test the performance of attention mechanism on aperiodic time-series data**.

4.5.2 Model without ML

To study the impact of `MAML` as well as optimization-based ML algorithms on `Temporal-ML`, we remove this component and only use the pure feature extraction methods introduced above: `BiLSTM`, `BiLSTM+CNN`, `Transformer`. Through this, **the ability to effectively synthesize the models of `MAML` and optimization-based ML algorithms in the problem of movement prediction of aperiodic time-series data will be clarified**.

Chapter 5

Results & Discussions

5.1 Main results

Kết quả chính của công trình này được thể hiện trong bảng 5.1. Theo đó, phương pháp đề xuất của chúng tôi đạt hiệu quả vượt trội trên tất cả các metrics trên cả hai tập dữ liệu phi chu kỳ (`USD/JPY`, `multi-fx`) so với `NHITS`. Trên các tập dữ liệu có chu kỳ (`ETT-m2`, `WTH`), mô hình của chúng tôi đạt hiệu quả gần như tương đương hoặc có phần tốt hơn so với baseline model.

Table 5.1: Classification results (%) of `Temporal-ML` and `NHITS`. Best results per metrics are boldfaced. (*): Our method.

		accuracy	*precision*	*recall*	$F1-score$
`USD/JPY`	`NHITS`	58.46	58.24	57.65	55.82
	`Temporal-ML`*	$\mathbf{70.33 \pm 1.69}$	$\mathbf{70.73 \pm 1.82}$	$\mathbf{70.26 \pm 1.93}$	$\mathbf{69.28 \pm 2.50}$
`multi-fx`	`NHITS`	53.51 ± 5.02	53.90 ± 7.68	53.64 ± 4.05	50.20 ± 7.35
	`Temporal-ML`*	$\mathbf{66.26 \pm 7.45}$	$\mathbf{67.08 \pm 8.97}$	$\mathbf{65.76 \pm 7.79}$	$\mathbf{64.06 \pm 10.00}$
`ETT-m2`	`NHITS`	**71.88**	**66.86**	**62.49**	**62.69**
	`Temporal-ML`*	71.14 ± 9.13	62.21 ± 7.51	58.75 ± 5.30	57.61 ± 6.74
`WTH`	`NHITS`	74.18	68.05	65.04	65.40
	`Temporal-ML`*	$\mathbf{74.97 \pm 2.63}$	$\mathbf{69.13 \pm 3.44}$	$\mathbf{65.98 \pm 3.96}$	$\mathbf{66.00 \pm 3.80}$

Cụ thể, trên hai tập dữ liệu phi chu kỳ `USD/JPY` và `multi-fx`, `Temporal-ML` cải thiện từ 12% đến 14% trên các metrics so với baseline model. Mặt khác, đối với dữ liệu có chu kỳ, độ chính xác của `Temporal-ML` thấp hơn chưa đến 1%, các metrics còn lại thấp hơn từ 4-5% so với `NHITS` trên dữ liệu `ETT-m2`. Đối với dữ liệu có tính chu kỳ mạnh như `WTH`, thuật toán của chúng tôi đạt hiệu suất tốt hơn `NHITS` khoảng 1%. Ngoài ra, `Temporal-ML` cũng đạt được mức phân tán trên các metrics thấp hơn `NHITS` từ 1-3% khi hoạt động trong ngữ cảnh dữ liệu đa nguồn. Quan sát tổng quan, sự chênh lệch của các metrics của cùng một phương pháp là không quá lớn nên không tồn tại vấn đề dữ liệu bị lệch và có

thể đánh giá mô hình bằng cách chỉ dựa trên độ chính xác.

Trong bảng 5.1, kết quả được tổng hợp dưới dạng trung bình cộng của tất cả các đặc trưng nên có tính đại diện cao. Tuy nhiên, các kết quả này thiếu đi sự chi tiết trong đánh giá. Do đó, chúng tôi tiến hành phân tích kết quả của các thuật toán trên từng attribute của aperiodic datasets trong bảng 5.2. Theo đó, khi `NHITS` dự đoán các thuộc tính *hight, low, close* price trên cả hai tập dữ liệu, kết quả đều chỉ đạt ở mức rất gần mô hình dự đoán ngẫu nhiên. Điều này cho thấy việc dự đoán trên aperiodic data thực sự rất khó khăn. Tuy nhiên, trên cả hai tập dữ liệu, độ chính xác của `NHITS` thường đạt giá trị lớn nhất khi dự đoán *open* price và lớn hơn đáng kể so với kết quả dự đoán các attribute còn lại. Do đó, khi lấy trung bình cộng, kết quả của `NHITS` có vẻ khá cao.

Table 5.2: Accuracy (%) of `Temporal-ML` and `NHITS` on each attribute of `USD/JPY` and `multi-fx`. Best results per metrics are boldfaced. (*): Our method.

		Open	*High*	*Low*	*Close*
`USD/JPY`	Random	49.91	49.91	50.33	50.66
	`NHITS`	75.03	53.74	51.57	53.50
	`Temporal-ML`*	$\mathbf{93.06 \pm 1.36}$	$\mathbf{68.87 \pm 1.53}$	$\mathbf{51.01 \pm 1.58}$	$\mathbf{68.37 \pm 2.16}$
`multi-fx`	Random	49.92 ± 2.19	49.93 ± 2.22	49.94 ± 2.17	49.85 ± 2.13
	`NHITS`	58.36 ± 7.13	50.66 ± 4.28	51.17 ± 3.21	53.84 ± 4.60
	`Temporal-ML`*	$\mathbf{78.13 \pm 6.33}$	$\mathbf{62.74 \pm 3.30}$	$\mathbf{58.28 \pm 3.86}$	$\mathbf{65.88 \pm 12.49}$

Mặt khác, `Temporal-ML` chỉ thất bại trong việc dự đoán *low* price của `USD/JPY` (độ chính xác tiệm cận mức dự đoán ngẫu nhiên). Tất cả các thuộc tính còn lại của cả hai tập dữ liệu đều đạt mức hội tụ cao và cao hơn `NHITS` khá nhiều. Điều này chứng tỏ khả năng vượt trội của thuật toán đề xuất trên dữ liệu phi chu kỳ.

Để làm rõ khả năng của `Temporal-ML`, dựa trên kết quả thu được từ các ablation experiments (section 4.5) chúng tôi tiến hành phân tích thuật toán đề xuất trên hai khía cạnh: (1) - Temporal feature extraction ability; (2) - Models' parameters aggregation ability.

5.2 Temporal feature extraction ability

Từ bảng 5.1 và 5.2, không khó để nhận ra khả năng rút trích temporal feature của `Temporal-ML` tốt hơn nhiều so với `NHITS`. Thật vậy, quá trình rút trích và tổng hợp đặc trưng của `NHITS` thể hiện rằng phương pháp này đang cố gắng mô phỏng lại quá trình phân giải tần số của Fourier transform. Đặc trưng về các giải tần là thông tin tối quan trọng đối với dữ liệu có chu kỳ. Do đó, các dự đoán của `NHITS` có thể dễ dàng đạt được độ chính xác cao trên loại dữ liệu này. Tuy nhiên, rất khó để có thể phân giải tần số trên dữ liệu phi chu kỳ. Hơn nữa, time-series data, dù được lọc qua nhiều stack để rút trích các dải

tần từ thấp đến cao, nhưng các kỹ thuật lọc được sử dụng trong mạng là vô cùng đơn giản (chỉ sử dụng `FullyConnected` với hàm kích hoạt phi tuyến và `Pooling` layers). Chính những điều này đã khiến cho `NHITS` gặp trở ngại lớn trên `multi-fx`, `USD/JPY` datasets và các dữ liệu phi chu kỳ nói chung.

Mặt khác, phương pháp đề xuất của chúng tôi sử dụng các mạng deep learning để rút trích đặc trưng. `BiLSTM` và `RNN` nói chung đã chúng tỏ được khả năng của chúng qua nhiều bài toán có liên quan đến các ràng buộc thời gian, rằng chúng có thể dễ dàng thu được các deep hidden feature. Do đó, trên cả periodic data lẫn aperiodic data, phương pháp của chúng tôi đều đạt được kết quả xấp xỉ hoặc cao hơn `NHITS`.

Để nắm bắt rõ hơn khả năng của `BiLSTM`, chúng tôi thực hiện ablation study trên component này của `Temporal-ML` như đã đề cập trong subsection 4.5.1 và trình bày kết quả trong bảng 5.3. Theo đó, khi `BiLSTM` được thay thế bởi các component khác (`BiLSTM+CNN`, `Transformer`) để phục vụ quá trình rút trích đặc trưng thời gian, kết quả trên cả bốn metrics của hầu hết các tập dữ liệu đều thấp hơn kết quả thu được từ `Temporal-ML`. Cụ thể, trên hai tập dữ liệu phi chu kỳ (`USD/JPY` and `multi-fx`), các thuật toán sử dụng `BiLSTM+CNN` và `Transformer` để rút trích đặc trưng cho khả năng dự đoán thấp hơn từ 2-10% so với `Temporal-ML`. Trên dữ liệu có chu kỳ, `MAML(Transformer)` vẫn cho kết quả thấp hơn nhiều so với `Temporal-ML`. Tuy nhiên `MAML(BiLSTM+CNN)` cho kết quả gần như tiệm cận với thuật toán đề xuất. Trên cả bốn datasets, độ lệch chuẩn của các metrics của thuật toán đề xuất nhìn chung nhỏ hơn từ 1-5% so với các thuật toán còn lại.

Table 5.3: Classification results (%) of `Temporal-ML` and models without `BiLSTM`. Best results per metrics are boldfaced. (*): Our method.

		accuracy	*precision*	*recall*	$F1-score$
USD/JPY	Temporal-ML*	$\mathbf{70.33 \pm 1.69}$	$\mathbf{70.73 \pm 1.82}$	$\mathbf{70.26 \pm 1.93}$	$\mathbf{69.28 \pm 2.50}$
	MAML(BiLSTM+CNN)	68.75 ± 1.78	69.15 ± 1.55	68.73 ± 1.77	69.14 ± 2.17
	MAML(Transformers)	60.67 ± 4.09	59.74 ± 6.24	59.32 ± 3.79	53.15 ± 6.19
multi-fx	Temporal-ML*	$\mathbf{66.26 \pm 7.45}$	$\mathbf{67.08 \pm 8.97}$	$\mathbf{65.76 \pm 7.79}$	$\mathbf{64.06 \pm 10.00}$
	MAML(BiLSTM+CNN)	66.08 ± 8.19	66.56 ± 9.23	65.41 ± 8.66	63.78 ± 10.83
	MAML(Transformers)	56.03 ± 6.08	56.32 ± 6.01	55.63 ± 5.01	52.33 ± 7.08
ETT-m2	Temporal-ML*	71.14 ± 9.13	62.21 ± 7.51	58.75 ± 5.30	57.61 ± 6.74
	MAML(BiLSTM+CNN)	$\mathbf{71.40 \pm 9.10}$	$\mathbf{63.25 \pm 8.82}$	$\mathbf{60.22 \pm 8.42}$	$\mathbf{59.43 \pm 9.24}$
	MAML(Transformers)	68.69 ± 8.85	58.54 ± 4.38	57.85 ± 4.71	57.07 ± 5.14
WTH	Temporal-ML*	$\mathbf{74.97 \pm 2.63}$	$\mathbf{69.13 \pm 3.44}$	$\mathbf{65.98 \pm 3.96}$	$\mathbf{66.00 \pm 3.80}$
	MAML(BiLSTM+CNN)	74.41 ± 2.71	68.17 ± 4.60	65.50 ± 4.82	65.63 ± 4.47
	MAML(Transformers)	72.28 ± 3.06	62.35 ± 8.73	60.90 ± 4.97	58.65 ± 4.72

Thông qua kết quả này, có thể nhận thấy việc sử dụng `BiLSTM` mang lại kết quả cao và ổn định trong quá trình dự đoán. Việc sử dụng các mạng như `CNN`, `Transformer` không những không tạo ra các cải thiện hiệu quả mà còn làm nhiễu quá trình học hoặc giảm hiệu quả của cả mô hình. Đối với việc sử dụng `BiLSTM+CNN`, quá trình học bị nhiễu do

bản thân BiLSTM đã chọn lọc được các ràng buộc thời gian hiệu quả trong quá trình rút trích trong khi CNN chỉ rút trích đặc trưng chứ không hề chọn lọc. Điều này dẫn đến việc đặc trưng của BiLSTM+CNN không ổn định. Nếu CNN rút trích được đặc trưng tốt, mạng sẽ hoạt động hiệu quả (e.g., metrics on ETT-m2). Ngược lại, mạng sẽ hoạt động kém hiệu quả hơn so với việc chỉ sử dụng BiLSTM (e.g., metrics on USD/JPY, multi-fx, WTH).

Ngoài ra, chúng tôi thực hiện phân tích quá trình hội tụ của Temporal-ML và các thuật toán nêu trên trên hai tập dữ liệu phi chu kỳ. Kết quả được trình bày trong hình 5.1a và 5.1b. Nhìn chung, trong quá trình dự đoán các attribute của USD/JPY và multi-fx, Temporal-ML đều cho độ chính xác cao và quá trình hội tụ nhanh. Riêng dự đoán *close* price trên multi-fx, MAML(BiLSTM+CNN) cho độ chính xác lẫn quá trình hội tụ tốt hơn thuật toán đề xuất. Điều đáng ngạc nhiên là MAML(Transformer) chỉ hội tụ khi dự đoán *open* price của cả hai tập dữ liệu foreign exchange. Chúng tôi cho rằng, để có thể sử dụng một mô hình phức tạp như Transformer, cần sử dụng một lượng lớn dữ liệu với số lượng inner epochs lớn. Điều này khiến cho Transformer không phải là một lựa chọn tốt khi kết hợp với các thuật toán ML.

Với các ý phân tích nêu trên, chúng tôi kết luận rằng, BiLSTM không chỉ là lựa chọn phù hợp trong việc khám phá sự biến thiên của aperiodic time-series data mà còn là thuật toán thích hợp để kết hợp với các thuật toán ML khi làm việc trên time-series data nói chung. **Bằng việc sử dụng BiLSTM, chúng tôi đã rút trích được sự biến động của thị trường cũng như dự đoán tương lai một cách hiệu quả**.

5.3 Models' parameters aggregation ability

Trong quá trình tổng hợp các đặc trưng để đưa ra dự đoán cuối, NHITS chỉ sử dụng các phép cộng trừ đơn giản. Điều này đặt trong ngữ cảnh của việc tổng hợp thông tin dựa trên các dải tần phân tách được từ dữ liệu đầu vào là hợp lý. Thật vậy, các dữ liệu liên quan đến thời tiết, nhu cầu sử dụng máy bay hoặc điện thể hiện tính chu kỳ rất mạnh vì thời tiết và hành vi tiêu dùng của con người, dù có thể chênh lệch theo thời gian nhưng vẫn thể hiện rất rõ tính mùa vụ (e.g., trời lạnh vào mùa đông, nhu cầu sử dụng máy bay tăng cao vào ngày lễ). Do đó, tần suất của loại dữ liệu này là một đặc trưng tốt và dễ dàng rút trích. Sau khi phân rã dữ liệu đầu vào thành các dải tần, chỉ cần tổng hợp chúng để có thể dự đoán tương lai. Ngoài ra, việc tổng hợp các dải tần bằng phép cộng đơn thuần có thể coi là rất đơn giản so với các thuật toán học sâu hiện tại, vốn làm việc trên không gian đặc trưng ẩn của dữ liệu. Do đó, quá trình tổng hợp của NHITS trên dữ liệu phi chu kỳ gặp rất nhiều khó khăn vì thông tin đầu vào cho quá trình tổng hợp không tốt và phương pháp tổng hợp không hiệu quả. Từ đây, có thể thấy rằng, aperiodic time-series data trở thành điểm yếu chí mạng cho NHITS và các phương pháp dựa trên

việc phân rã tần số nói chung.

Đối diện với sự phức tạp trong dữ liệu phi chu kỳ đòi hỏi một cấu trúc phức tạp để có thể tổng hợp các đặc trưng một cách hợp hiệu quả. Như đã đề cập trong phần Motivation (section 1.2), việc phân tích và tổng hợp thông tin từ nhiều nguồn dữ liệu trong cùng một domain có thể cung cấp các thông tin hữu ích trong việc dự đoán các chỉ số quan tâm. `Temporal-ML` với khả năng tổng hợp thông tin dựa trên quá trình tối ưu của các thuật toán ML, cho phép mô hình nắm bắt thông tin đa chiều từ các nguồn dữ liệu khác nhau. Từ đó đưa ra dự đoán hiệu quả.

Để nắm bắt rõ khả năng của các thuật toán ML trong `Temporal-ML`, chúng tôi loại bỏ component này khỏi thuật toán đề xuất sau đó chạy thực nghiệm để so sánh với kết quả ban đầu (subsection 4.5.2). Chúng tôi sử dụng các thuật toán ML nhằm mục đích tổng hợp thông tin đa nguồn. Do đó, các so sánh chỉ được thực hiện trên tập dữ liệu `multi-fx` vì chỉ tập dữ liệu này chứa nhiều tập dữ liệu con từ nhiều nguồn khác nhau. Kết quả được tổng hợp trong bảng 5.4. Theo đó, với khả năng tổng hợp thông tin của mình, `Temporal-ML` cho kết quả cao hơn từ 2-12% so với các thuật toán không sử dụng ML trong quá trình huấn luyện. Ngoài ra, mức phân tán của các metrics cũng thấp hơn từ 1-7%, chứng tỏ rằng mức chênh lệch trong quá trình dự đoán các task tốt hơn nhiều so với các thuật toán còn lại.

Việc đạt được kết quả tốt hơn trên `multi-fx` của `Temporal-ML` là hoàn toàn dễ hiểu vì tất cả phương pháp còn lại trong bảng 5.4 đều không có khả năng tổng hợp thông tin như thuật toán đề xuất mà chỉ dựa hoàn toàn vào dữ liệu quá khứ để dự đoán tương lai. Do đó, không chỉ `BiLSTM`, `BiLSTM+CNN` mà ngay cả `Transformer` cũng không thể tận dụng được mối tương quan giữa các data sources.

Table 5.4: Classification results (%) of `Temporal-ML` and models without `MAML` on `multi-fx`. Best results per metrics are boldfaced. (*): Our method.

	accuracy	*precision*	*recall*	$F1 - score$
`Temporal-ML`*	$\mathbf{66.26 \pm 7.45}$	$\mathbf{67.08 \pm 8.97}$	$\mathbf{65.76 \pm 7.79}$	$\mathbf{64.06 \pm 10.00}$
`BiLSTM`	63.88 ± 9.00	64.18 ± 13.39	63.66 ± 9.13	60.07 ± 13.09
`BiLSTM+CNN`	62.23 ± 8.63	62.89 ± 9.76	62.20 ± 8.34	59.91 ± 10.97
`Transformers`	58.44 ± 9.15	56.71 ± 15.10	58.22 ± 8.84	52.22 ± 13.12

Quá trình hội tụ của `Temporal-ML` và các model without ML được trình bày trong hình 5.1c. Trong đó, khi dự đoán *open* price, thuật toán đề xuất cho khả năng hội tụ vượt trội so với các thuật toán còn lại. Đối với các thuộc tính *high* price và *close* price, `Temporal-ML` tỏ ra đuối sức trong giai đoạn đầu của quá trình huấn luyện. Tuy nhiên, khi về cuối, mô hình đề xuất cho thấy khả năng vượt lên nhanh chóng và tiềm năng cải thiện độ chính xác hơn nữa so với các thuật toán khác, vốn đã hội tụ.

Do đó, có thể thấy rằng, **việc sử dụng các thuật toán optimization-based ML trong việc tổng hợp thông tin là hoàn toàn hợp lý vì đã tận dụng thành công mối tương quan giữa các tập dữ liệu và đạt được độ chính xác cao mà không đòi hỏi quá nhiều dữ liệu như trong ngữ cảnh đơn nguồn**.

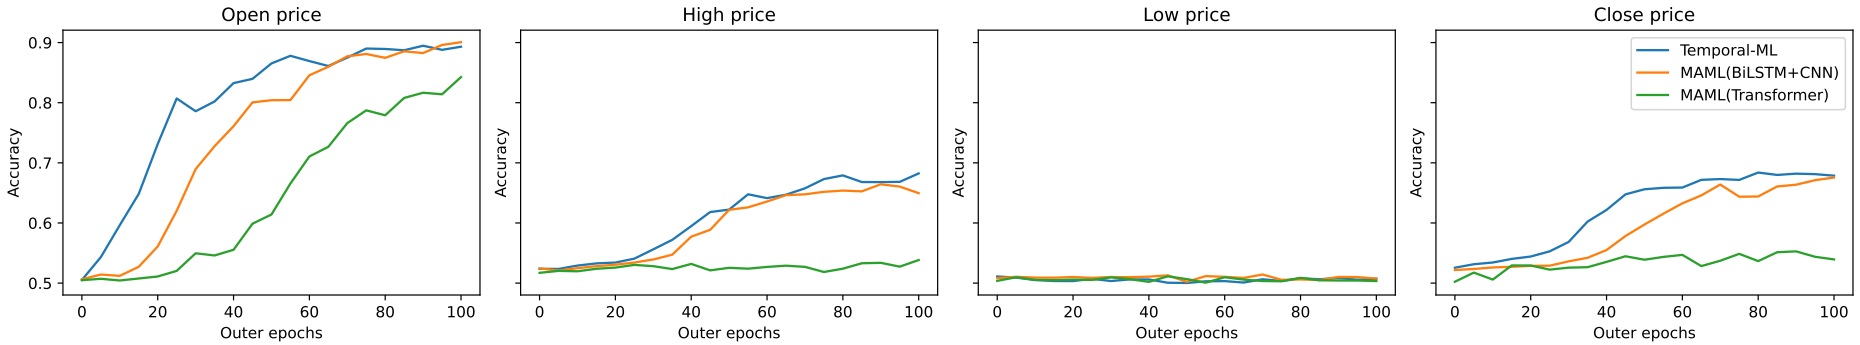

(a) `Temporal-ML` vs. Models without `BiLSTM` on `USD/JPY`.

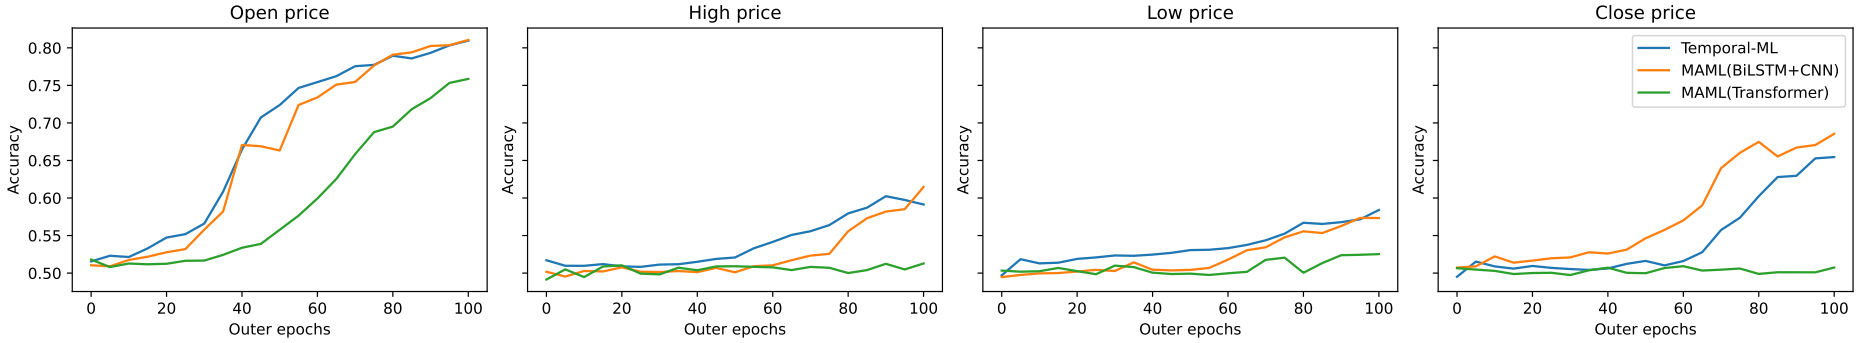

(b) `Temporal-ML` vs. Models without `BiLSTM` on `multi-fx`.

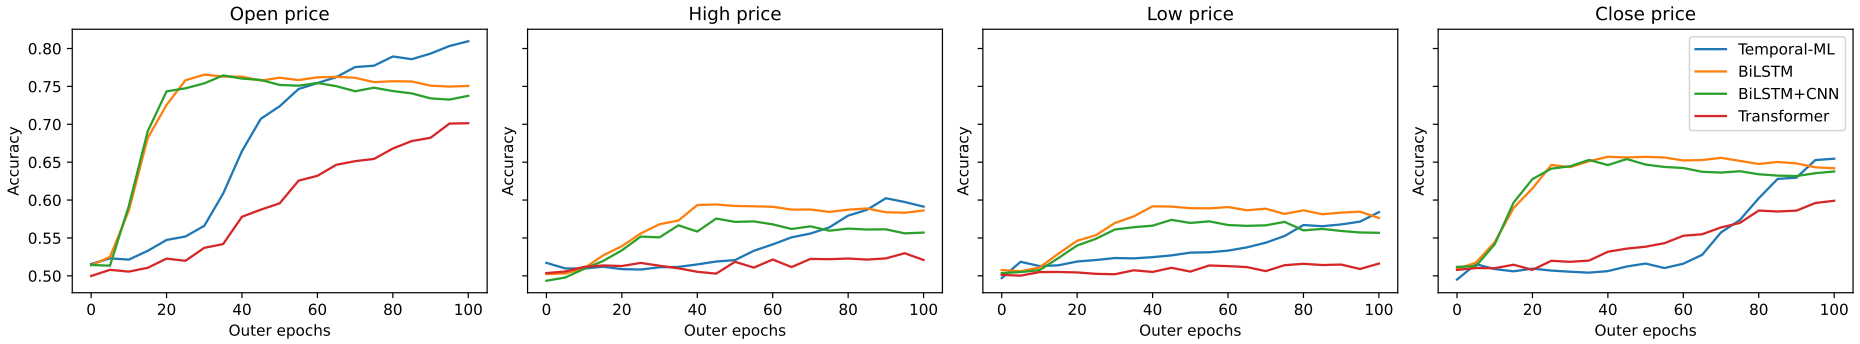

(c) `Temporal-ML` vs. Models without `MAML` on `multi-fx`.

Figure 5.1: Convergence process of algorithms in ablation study on all attribute of foreign exchange datasets.

Chapter 6

Conclusions & Future works

6.1 Conclusions

Các bài toán trên aperiodic time-series data đặt ra một thử thách lớn cho các mô hình học máy hiện nay vì dữ liệu này phụ thuộc vào cả lịch sử giao dịch lẫn các external factor như tình hình kinh tế, chính trị; variance của dữ liệu thay đổi liên tục; tính phi chu kỳ của dữ liệu thể hiện rất mạng. Trong khi các thách thức này trở nên rất đặc thù cho dữ liệu và yêu cầu một phương pháp được thiết kế riêng, các thuật toán hiện tại hầu như không tập trung giải quyết các thách thức này mà chỉ hướng đến time-series nói chung. Thật vậy, các phương pháp học sâu như `LSTM`, `CNN`, `Transformer` được thiết kế để phân tích dữ liệu dạng chuỗi nói chung. Đối với dạng dữ liệu đặc thù như aperiodic time-series data, chúng trở nên kém hiệu quả do hạn chế trong việc lưu trữ các ràng buộc thời gian. Các phương pháp dựa trên phân rã tần số như `NHITS` và `bla_bla` hướng đến phân rã tín hiệu đầu vào thành các dải tần nhưng tính chu kỳ hoàn toàn không tồn tại trong aperiodic time-series data.

Ý thức được các thách thức nêu trên cùng với việc tận dụng khả năng rút trích ràng buộc thời gian của `BiLSTM` và khả năng tổng hợp tham số hiệu quả của `MAML`, chúng tôi đề xuất thuật toán `Temporal-ML` với khả năng rút trích thời gian đặc trưng ẩn cũng như tổng hợp thông tin từ dữ liệu đa nguồn. Dựa trên thực nghiệm, trong quá trình giải quyết bài toán dự đoán xu hướng tiếp theo, phương pháp đề xuất đạt hiệu quả cao trên hai tập dữ liệu phi chu kỳ (`USD/JPY` và `multi-fx`) và hiệu quả tương đương trên các tập dữ liệu có chu kỳ (`ETT-m2` và `WTH`) so với `NHITS` (SOTA model in AAAI 2023). Ngoài ra, bằng việc thực hiện ablation study, chúng tôi chứng minh được sự hiệu quả của từng component trong `Temporal-ML`. Cụ thể, khả năng rút trích hiệu quả các ràng buộc thời gian đến từ `BiLSTM` và khả năng tổng hợp thông tin đa nguồn đến từ `MAML`. Theo đó, thuật toán của chúng tôi đã giải quyết hiệu quả vấn đề dữ liệu phụ thuộc vào external factor, vấn đề variance bất định và vấn đề phi chu kỳ của dữ liệu.

6.2 Future works

In the future, we propose two main directions of development related to the architecture and personalization of the model

Model architecture. Phương pháp của chúng tôi được phát triển dưới dạng component với hai components chính hoạt động song song: Temporal feature extraction and Models' parameter synthesis. Điều này cung chấp cho phương pháp của chúng tôi một khả năng nâng cấp linh hoạt. Thí nghiệm của chúng tôi chỉ minh họa một trường hợp điển hình trong tổng hợp hiệu quả các đặc trưng. Bằng việc sử dụng các thuật toán ML khác nhau như `iMAML`, `Reptile`, hoàn toàn có thể tạo ra mô hình mới với độ chính xác cao hơn.

Long-horizon problem. Hoàn toàn có thể mở rộng phương pháp này để giải các bài toán về long-horizon prediction. Thật vậy, bằng việc thay đổi đầu ra và độ lỗi của mô hình, có thể tiến hành giải các bài toán này. Tuy nhiên, kiến trúc của các sub-model cần được nghiên cứu lại để phù hợp hơn với bài toán mới.

Bibliography

[1] A. C. Ian Goodfellow, Yoshua Bengio, "Deep learning," 2016.

[2] C. Challu, K. G. Olivares, B. N. Oreshkin, F. G. Ramirez, M. M. Canseco, and A. Dubrawski, "Nhits: Neural hierarchical interpolation for time series forecasting," in *Proceedings of the AAAI conference on artificial intelligence*, vol. 37, pp. 6989–6997, 2023.

[3] M. Ayitey Junior, P. Appiahene, O. Appiah, and C. N. Bombie, "Forex market forecasting using machine learning: Systematic literature review and meta-analysis," *Journal of Big Data*, vol. 10, no. 1, p. 9, 2023.

[4] P. A. Moran, "Hypothesis testing in time series analysis," *Royal Statistical Society. Journal. Series A: General*, vol. 114, pp. 579–579, 7 1951.

[5] M. Rosenblatt, *Gaussian and non-Gaussian linear time series and random fields*. Springer Science & Business Media, 2000.

[6] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural computation*, vol. 9, no. 8, pp. 1735–1780, 1997.

[7] A. Vaswani, "Attention is all you need," *Advances in Neural Information Processing Systems*, 2017.

[8] M. Liu, A. Zeng, M. Chen, Z. Xu, Q. Lai, L. Ma, and Q. Xu, "Scinet: Time series modeling and forecasting with sample convolution and interaction," *Advances in Neural Information Processing Systems*, vol. 35, pp. 5816–5828, 2022.

[9] M. Chen, H. Peng, J. Fu, and H. Ling, "Autoformer: Searching transformers for visual recognition," in *Proceedings of the IEEE/CVF international conference on computer vision*, pp. 12270–12280, 2021.

[10] T. Zhou, Z. Ma, Q. Wen, X. Wang, L. Sun, and R. Jin, "Fedformer: Frequency enhanced decomposed transformer for long-term series forecasting," in *International conference on machine learning*, pp. 27268–27286, PMLR, 2022.

[11] H. Zhou, S. Zhang, J. Peng, S. Zhang, J. Li, H. Xiong, and W. Zhang, "Informer: Beyond efficient transformer for long sequence time-series forecasting," in *Proceedings of the AAAI conference on artificial intelligence*, vol. 35, pp. 11106–11115, 2021.

[12] H. Liu, Z. Wang, X. Dong, and J. Du, "Onsitnet: A memory-capable online time series forecasting model incorporating a self-attention mechanism," *Expert Systems with Applications*, vol. 259, p. 125231, 2025.

[13] E. F. Fama, "Efficient capital markets: A review of theory and empirical work," *Journal of finance*, vol. 25, no. 2, pp. 383–417, 1970.

[14] A. C. M. Andraw W. Lo, "When are contrarian profits due to stock market overreaction?," *The review of financial studies*, vol. 3, no. 2, pp. 175–205, 1990.

[15] T. S. Mech, "Portfolio return autocorrelation," *Journal of Financial Economics*, vol. 34, no. 3, pp. 307–344, 1993.

[16] M. Ali, R. Prasad, Y. Xiang, and Z. M. Yaseen, "Complete ensemble empirical mode decomposition hybridized with random forest and kernel ridge regression model for monthly rainfall forecasts," *Journal of Hydrology*, vol. 584, p. 124647, 2020.

[17] T. Zafeiriou and D. Kalles, "Intraday ultra-short-term forecasting of foreign exchange rates using an ensemble of neural networks based on conventional technical indicators," in *11th Hellenic Conference on Artificial Intelligence*, pp. 224–231, 2020.

[18] A. Sadeghi, A. Daneshvar, and M. M. Zaj, "Combined ensemble multi-class svm and fuzzy nsga-ii for trend forecasting and trading in forex markets," *Expert Systems with Applications*, vol. 185, p. 115566, 2021.

[19] Y. LeCun, B. Boser, J. Denker, D. Henderson, R. Howard, W. Hubbard, and L. Jackel, "Handwritten digit recognition with a back-propagation network," *Advances in neural information processing systems*, vol. 2, 1989.

[20] D. Bahdanau, "Neural machine translation by jointly learning to align and translate," *arXiv preprint arXiv:1409.0473*, 2014.

[21] M.-T. Luong, "Effective approaches to attention-based neural machine translation," *arXiv preprint arXiv:1508.04025*, 2015.

[22] T. Hospedales, A. Antoniou, P. Micaelli, and A. Storkey, "Meta-learning in neural networks: A survey," *IEEE transactions on pattern analysis and machine intelligence*, vol. 44, no. 9, pp. 5149–5169, 2021.

[23] A. Vettoruzzo, M.-R. Bouguelia, J. Vanschoren, T. Rognvaldsson, and K. Santosh, "Advances and challenges in meta-learning: A technical review," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2024.

[24] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, "Learning representations by back-propagating errors," *nature*, vol. 323, no. 6088, pp. 533–536, 1986.

[25] F. Chen, M. Luo, Z. Dong, Z. Li, and X. He, "Federated meta-learning with fast convergence and efficient communication," *arXiv preprint arXiv:1802.07876*, 2018.

[26] A. Fallah, A. Mokhtari, and A. Ozdaglar, "Personalized federated learning: A meta-learning approach," *arXiv preprint arXiv:2002.07948*, 2020.

[27] B.-L. Nguyen, T. C. Cao, and B. Le, "Meta-learning and personalization layer in federated learning," in *Asian Conference on Intelligent Information and Database Systems*, pp. 209–221, Springer, 2022.

[28] N. Hu, E. Mitchell, C. D. Manning, and C. Finn, "Meta-learning online adaptation of language models," *arXiv preprint arXiv:2305.15076*, 2023.

[29] Z. Li, F. Zhou, F. Chen, and H. Li, "Meta-sgd: Learning to learn quickly for few-shot learning," *arXiv preprint arXiv:1707.09835*, 2017.

[30] C. Finn, P. Abbeel, and S. Levine, "Model-agnostic meta-learning for fast adaptation of deep networks," in *International conference on machine learning*, pp. 1126–1135, PMLR, 2017.

[31] O. Kolle, "Weather dataset," 2008.

[32] A. Garza, "Neural forecast - user friendly state-of-the-art neural forecasting models."